

به نام خدا



دانشگاه تهران  
پردیس دانشکده‌های فنی  
دانشکده برق و کامپیوتر



شناسائی الگو

تمرین شماره ۲

نام و نام خانوادگی  
سجاد پاکدامن ساوجی  
شماره دانشجویی  
۸۱۰۱۹۵۵۱۷

## فهرست

عنوان	شماره صفحه
چکیده	۳
تمرین 1	4
تمرین 2	6
	15
تمرین ۳	17
تمرین ۴	19
	20
تمرین ۵	
تمرین ۶	

## چکیده

در این تمرین با مباحثی از درس مانند MAP ، ML و EM آشنا شدیم. همچنان به صورت امتیازی با hidden markov models آشنا شدیم.

## Pattern Recognition Assignment 2

Problem 1)

$$I. f(x^q | \mu) = \frac{1}{(2\pi)^{\frac{Q}{2}} |\Sigma|^{-\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (x^q - \mu)^T \Sigma^{-1} (x^q - \mu) \right\}$$

$$f(\mu) = \frac{1}{(2\pi)^{\frac{Q}{2}} |\Sigma|^{-\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mu - m_0)^T \Sigma^{-1} (\mu - m_0) \right\}$$

$$\hat{\theta}_{MAP} = \arg \max_{\theta} f(\theta | x) = \arg \max_{\theta} f(x | \theta) f(\theta)$$

$$= \arg \max_{\theta} \left( \prod_{q=1}^Q f(x^q | \theta) \right) f(\theta) \xrightarrow{\ln} \arg \max_{\theta} \sum_{q=1}^Q \ln f(x^q | \theta) + \ln f(\theta)$$

$$L(\theta) = \sum_{q=1}^Q \left[ -\frac{Q}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} (x^q - \mu)^T \Sigma^{-1} (x^q - \mu) \right] - \frac{Q}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} (\mu - m_0)^T \Sigma^{-1} (\mu - m_0)$$

$$\frac{\partial L(\theta)}{\partial \theta} = 0 \Rightarrow \sum_{q=1}^Q \left[ -\frac{1}{2} (2 \Sigma^{-1} \mu - 2 \Sigma^{-1} x^q) \right] - \frac{1}{2} (2 \Sigma^{-1} \mu - 2 \Sigma^{-1} m_0) = 0$$

$$\Rightarrow (Q \Sigma^{-1} + \Sigma^{-1}) \mu = \Sigma^{-1} \sum_{q=1}^Q x^q + \Sigma^{-1} m_0$$

$$\Rightarrow \hat{\mu}_{MAP} = (Q \Sigma^{-1} + \Sigma^{-1})^{-1} \left[ \Sigma^{-1} \sum_{q=1}^Q x^q + \Sigma^{-1} m_0 \right]$$

برای است که ضریب تغییر باشد (نقاست خطی) با پاسخ به رابطه مستقیم دارد.

اگر نقاست خطی یک به یک، پوشا باشد رابطه بین  $\tilde{\mu}$  و  $\mu$  برقرار نخواهد بود

$$\tilde{\mu} = E\{\tilde{x}\} = E\{Ax\} = A E\{x\} = A\mu \Rightarrow \tilde{m}_0 = Am_0$$

$$\tilde{\Sigma} = E\{(\tilde{x} - \tilde{\mu})(\tilde{x} - \tilde{\mu})^T\} = E\{A(x - \mu)(x - \mu)^T A^T\} = A \Sigma A^T$$

$$\Rightarrow \tilde{\Sigma} = A \Sigma A^T$$

بدون از دست رفتن کلیات  $A \leftarrow$  unitary

$$\tilde{\mu} = (Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1})^{-1} \left[ \tilde{\Sigma}^{-1} \sum_{q=1}^Q \tilde{x}^q + \tilde{\Sigma}^{-1} \tilde{m} \right]$$

$$Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1} = Q A \tilde{\Sigma}^{-1} A^T + A \tilde{\Sigma}^{-1} A^T = A [Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1}] A^T$$

$$\Rightarrow (Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1})^{-1} = (A [Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1}] A^T)^{-1} = A [Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1}]^{-1} A^T$$

$$\begin{aligned} \tilde{\Sigma}^{-1} \sum_{q=1}^Q \tilde{x}^q + \tilde{\Sigma}^{-1} \tilde{m} &= A \tilde{\Sigma}^{-1} A^T \left( A \sum_{q=1}^Q x^q \right) + A \tilde{\Sigma}^{-1} A^T A m \\ &= A \left( \tilde{\Sigma}^{-1} \sum_{q=1}^Q x^q + \tilde{\Sigma}^{-1} m \right) \end{aligned}$$

$$\Rightarrow \tilde{\mu} = A [Q \tilde{\Sigma}^{-1} + \tilde{\Sigma}^{-1}]^{-1} A^T A \left[ \tilde{\Sigma}^{-1} \sum_{q=1}^Q x^q + \tilde{\Sigma}^{-1} m \right] = A \mu$$

در نتیجه  $A$  unitary است، و این به سبب آنست که  $\mu$  و  $\tilde{\mu}$  هر دو هم مقادیر هستند.

$$II. f(x^q | \mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\}$$

$$f(\mu) = \mu \exp \left\{ -\frac{\mu^2}{2\sigma_\mu^2} \right\}$$

$$\hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} \underbrace{\sum_{q=1}^Q f(x^q | \mu)}_{L(\theta)} + \underbrace{\ln f(\mu)}_{L(\theta)}$$

$$L(\theta) = \sum_{q=1}^Q \left( -\frac{1}{2} \ln 2\pi - \ln \sigma - \frac{(\mu - x^q)^2}{2\sigma^2} \right) - \ln \sigma_\mu^2 + \ln \mu - \frac{\mu^2}{2\sigma_\mu^2}$$

$$\frac{\partial L(\theta)}{\partial \theta} = 0 \Rightarrow \sum_{q=1}^Q \frac{2(\mu - x^q)}{2\sigma^2} - \frac{1}{\mu} + \frac{2\mu}{2\sigma_\mu^2} = 0$$


$$\Rightarrow \underbrace{-\sum_{q=1}^Q \frac{x^q}{\sigma^2}}_Z - \frac{1}{\mu} + \underbrace{\left( \frac{Q}{\sigma^2} + \frac{1}{\sigma_\mu^2} \right)}_R \mu = 0 \Rightarrow \mu^2 - \frac{Z}{R} \mu - \frac{1}{R} = 0$$

$$\Rightarrow \mu = \frac{\frac{Z}{R} \pm \sqrt{\left(\frac{Z}{R}\right)^2 + \frac{4}{R}}}{2} = \frac{Z}{2R} \left( 1 \pm \sqrt{1 + \frac{4R}{Z^2}} \right)$$

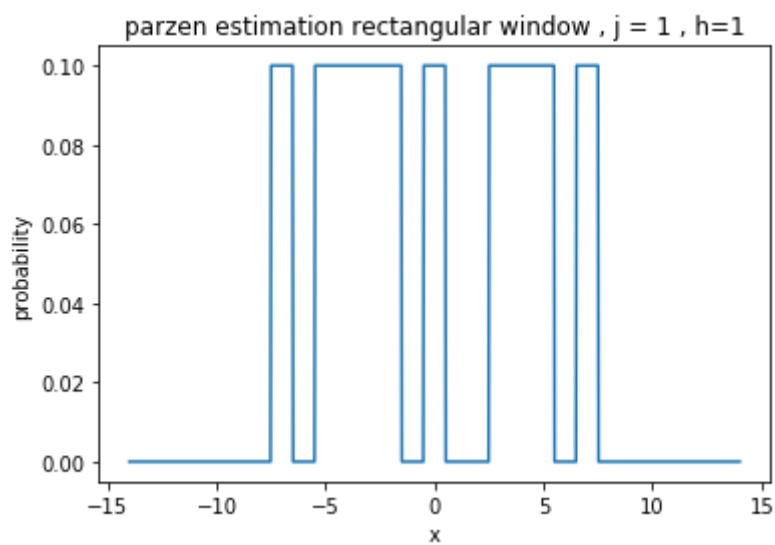

## سوال 2

محاسبات مربوط به این سوال در فایل p2.inpy قرار دارد و پلات ها و نتایج آن در زیر آمده است.

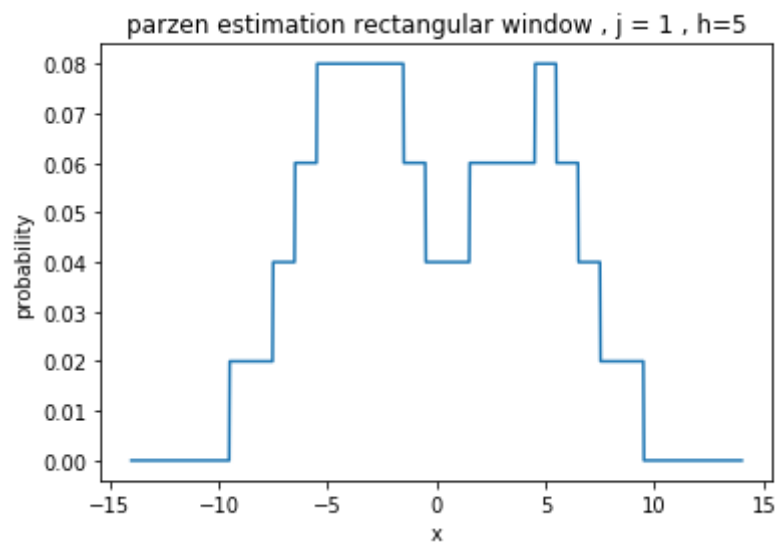

قسمت ۱ (a)



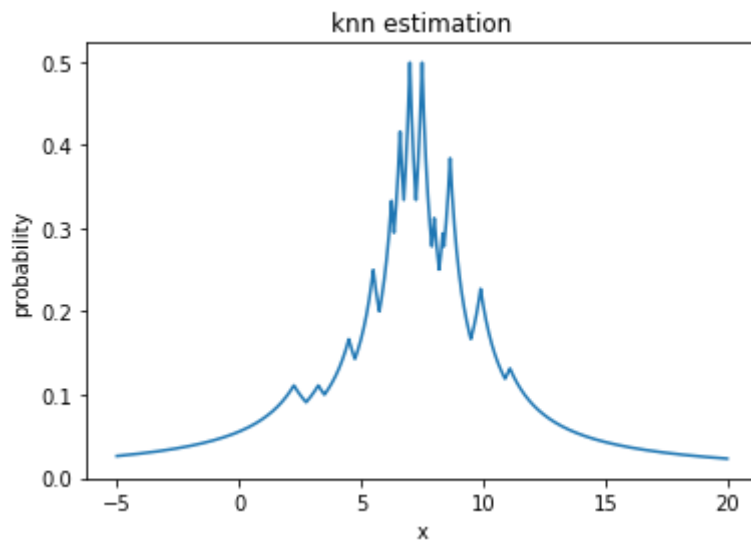
a)



قسمت ( ۱ ) ( b )







**knn estimate (2 , k = 4) = 0.1**

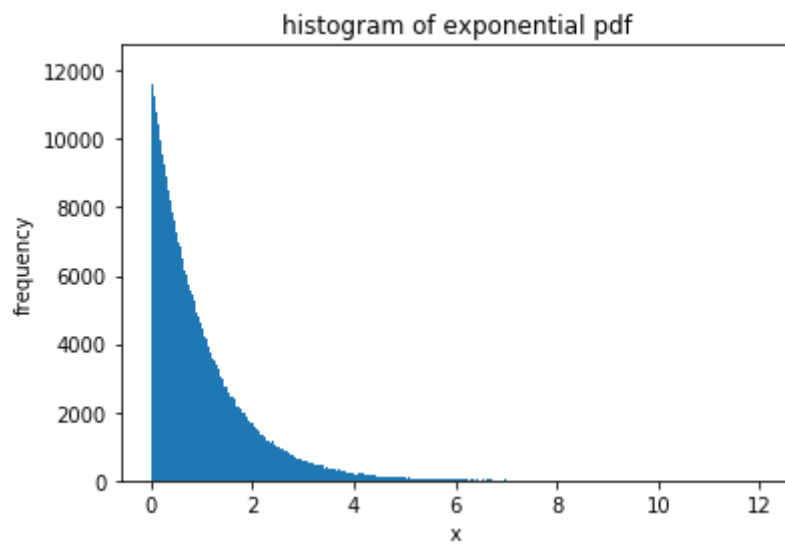
**knn estimate (4 , k = 4) = 0.125**

**knn estimate (6 , k = 4) = 0.25**

**knn estimate (8 , k = 4) = 0.312**

**knn estimate (10 , k = 4) = 0.208**

قسمت ۲ (بخش ۲) (a)



قسمت ۲ (بخش ۲) (b)

**std\_10 = 1.70**

**std\_100 = 0.9602**




**std\_1000 = 0.9665**

**h\*\_10 = 0.5711**




**h\*\_100 = 0.1017**

**h\*\_1000 = 0.032**

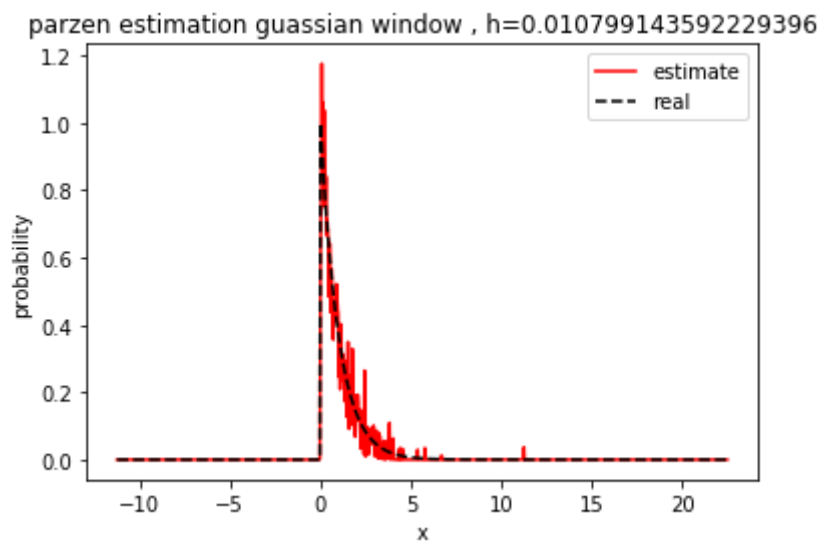
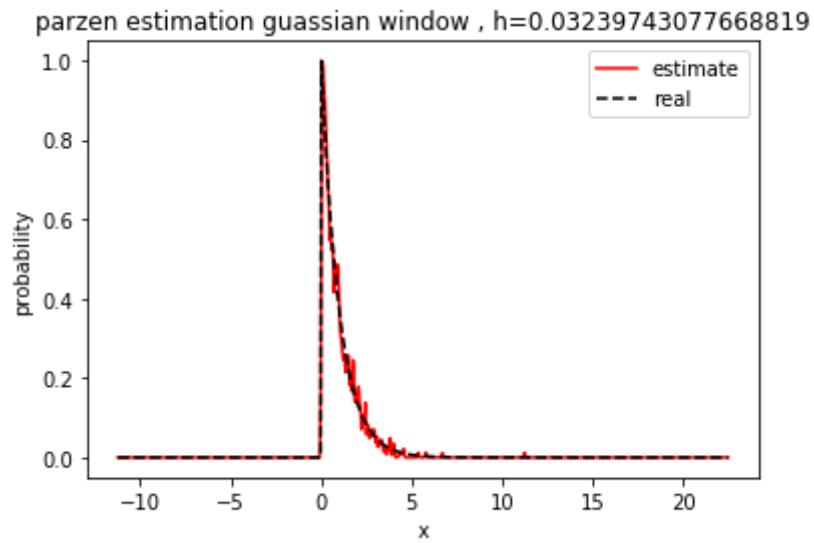

برای تعداد داده ۱۰ داریم :



برای تعداد داده ۱۰۰ داریم:



برای تعداد داده ۱۰۰۰ داریم:



نتیجه گیری: خود kernel تاثیر مستقیم روی کیفیت تخمین دارد و همان طور که مشاهده کردیم kernel گوسی از kernel مربعی بهتر عمل کرد زیرا این کرنل وزن یکسانی به داده ها نمیدهد.

نقش  $N$  به این صورت است که هر چه  $N$  بیشتر باشد ما تعداد داده های بیشتری داریم و در نتیجه کیفیت تخمین ما بهتر خواهد شد. و در حالت حدی که  $n$  خیلی بزرگ است در این صورت دیگر مهم نیست که از چه کرنلی استفاده کنیم در هر حال کیفیت تخمین مناسب است.

نقش  $h$  در حقیقت یک اسکیل ساده است. از آن حایی که در حوزه فرکانس کرنل و توزیع با یک دیگر کانوالو میشوند، پس تفسیر دیگری را  $h$  همان پهنای باند در حوزه فرکانس است.  $h$  در این مفهوم اجازه نمیدهد تغییرات زیاد وارد تخمین شود و در نتیجه تابع تخمین زده شده نرم تر خواهد شد.

## Problem 3) ML-Estimation

I.

$$a. \hat{\theta}_{ML} = \underset{\theta}{\operatorname{argmax}} f(x|\theta) \quad \hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} f(x|\theta) f(\theta)$$

باید به رابطه بالا نقش  $f(\theta)$  regularization را اضافه کنیم. در حالت کلی می‌توان این regularization را به صورت زیر نوشت:

$$\hat{\mu}_{MAP} = \frac{\left(\frac{\sigma^2 \mu}{\sigma^2}\right)^2 \sum_{q=1}^Q x^q + \mu}{Q \left(\frac{\sigma^2 \mu}{\sigma^2}\right)^2 + 1}$$

برای مثال برای چکانگ لوسی با تخمین  $\hat{\theta}_{MAP}$  به صورت زیر است:

$$\frac{\sigma^2 \mu}{\sigma^2} \gg 1 \rightarrow \hat{\mu}_{MAP} = \hat{\mu}_{ML}$$

$$\frac{\sigma^2 \mu}{\sigma^2} \ll 1 \rightarrow \hat{\mu}_{MAP} = \mu_0$$

$$b. \hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} f(x|\theta) f(\theta) \xrightarrow{\ln} \hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} \ln f(x|\theta) + \ln f(\theta)$$

$$\xrightarrow{iid} \underset{\theta}{\operatorname{argmax}} \ln \prod_{q=1}^Q f(x^q|\theta) + \ln f(\theta) \xrightarrow{\text{naive}} \underset{\theta}{\operatorname{argmax}} \ln \prod_{q=1}^Q \prod_{k=1}^N f(x_k^q|\theta) + \ln f(\theta)$$

conditional independence

$$\Rightarrow \hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} \sum_{q=1}^Q \sum_{k=1}^N \ln f(x_k^q|\theta) + \ln f(\theta)$$

این naive bayes تخمین MAP را به صورت بالا می‌توان نوشت.

II.

$$a) f(x_k|\theta) = \frac{1}{\sigma x_k \sqrt{2\pi}} \exp \left\{ -\frac{(\ln x_k - \theta)^2}{2\sigma^2} \right\} \quad x_k > 0$$

$$\Rightarrow \hat{\theta}_{ML} = \underset{\theta}{\operatorname{argmax}} \sum_{q=1}^Q \ln \left( \frac{1}{\sigma x^q \sqrt{2\pi}} \right) - \frac{(\ln x^q - \theta)^2}{2\sigma^2} = \sum_{q=1}^Q -\ln \sigma - \ln x^q - \frac{1}{2} \ln 2\pi - \frac{(\ln x^q - \theta)^2}{2\sigma^2}$$

$$\frac{\partial l(\theta)}{\partial \theta} = \sum_{q=1}^Q \frac{-2(\ln x^q - \theta)}{2\sigma^2} = 0 \Rightarrow \sum_{q=1}^Q \frac{-\theta}{\sigma^2} + \frac{\ln x^q}{\sigma^2} = 0$$

$$\Rightarrow Q\theta = \sum_{q=1}^Q \ln x^q \Rightarrow \hat{\theta}_{ML} = \frac{1}{Q} \sum_{q=1}^Q \ln x^q$$

$$b. f(x^q|\theta) = \frac{1}{\Gamma(\alpha)} \theta^\alpha x^{q\alpha-1} \exp\{-\theta x^q\}$$

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta} \sum_{q=1}^Q \ln \Gamma(\alpha) + \alpha \ln \theta + (\alpha-1) \ln x^q - \theta x^q$$

$$\frac{\partial L(\theta)}{\partial \theta} = \sum_{q=1}^Q \alpha x \frac{1}{\theta} - x^q = 0 \Rightarrow \frac{\alpha Q}{\theta} = \sum_{q=1}^Q x^q \Rightarrow \hat{\theta}_{ML} = \frac{\alpha Q}{\sum_{q=1}^Q x^q}$$

$$c. f(x^q|\theta) = \sqrt{\theta} x^{q\sqrt{\theta}-1}$$

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta} \sum_{q=1}^Q \frac{1}{2} \ln \theta + (\sqrt{\theta}-1) \ln x^q$$

$$\frac{\partial L(\theta)}{\partial \theta} = \sum_{q=1}^Q \frac{1}{2\theta} + \frac{\ln x^q}{2\sqrt{\theta}} = 0 \Rightarrow \sum_{q=1}^Q \frac{1 + \sqrt{\theta} \ln x^q}{2\theta} = 0$$

$$\Rightarrow Q + \sqrt{\theta} \sum_{q=1}^Q \ln x^q = 0 \Rightarrow \sqrt{\theta} = \frac{-Q}{\sum_{q=1}^Q \ln x^q} \Rightarrow \hat{\theta}_{ML} = \left( \frac{-Q}{\sum_{q=1}^Q \ln x^q} \right)^2$$

$$d. f(x^q|\theta) = \theta^2 x^q \exp\{-\theta x^q\} u(x^q) \quad \theta > 0, x^q > 0$$

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta} \sum_{q=1}^Q 2 \ln \theta + \ln x^q - \theta x^q + \ln u(x^q)$$

$$\frac{\partial L(\theta)}{\partial \theta} = \sum_{q=1}^Q \frac{2}{\theta} - x^q = 0 \Rightarrow \hat{\theta}_{ML} = \frac{2Q}{\sum_{q=1}^Q x^q}$$



Problem 4) Expectation Maximization

$$f(x^t | \theta, j) = \frac{1}{\sqrt{2\pi}\sigma_j} \exp \left\{ -\frac{(x^t - \mu_j)^2}{2\sigma_j^2} \right\}$$

$$Q(\theta | \hat{\theta}^{(t)}, \lambda) = \sum_{q=1}^Q \sum_{j=1}^J p(j | \hat{\theta}^{(t)}, x^q) \left[ \frac{-(x^q - \mu_j)^2}{2\sigma_j^2} - \frac{n}{2} \ln 2\pi\sigma_j^2 + \ln p_j \right]$$

$$a). \sum_{j=1}^J p_j = 1$$

$$\Rightarrow L(\theta, \lambda) = \sum_{q=1}^Q \sum_{j=1}^J p(j | \hat{\theta}^{(t)}, x^q) \left[ \frac{-(x^q - \mu_j)^2}{2\sigma_j^2} - \frac{n}{2} \ln 2\pi\sigma_j^2 + \ln p_j \right] - \lambda \left[ \sum_{j=1}^J p_j - 1 \right]$$

$$\frac{\partial L(\theta, \lambda)}{\partial \mu_j} = \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) \left[ \frac{-(x^q - \mu_j)}{\sigma_j^2} \right] = 0 \Rightarrow \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) [x^q - \mu_j] = 0$$

$$\Rightarrow \mu_j \sum_{q=1}^Q p(j | x^q, \hat{\theta}^{(t)}) = \sum_{q=1}^Q p(j | x^q, \hat{\theta}^{(t)}) x^q \Rightarrow \hat{\mu}_{j(t+1)} = \frac{\sum_{q=1}^Q p(j | x^q, \hat{\theta}^{(t)}) x^q}{\sum_{q=1}^Q p(j | x^q, \hat{\theta}^{(t)})}$$

$$\frac{\partial L(\theta, \lambda)}{\partial \sigma_j^2} = \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) \left[ \frac{-(x^q - \mu_j)^2}{2(\sigma_j^2)^2} - \frac{n}{2} \times \frac{1}{2\pi\sigma_j^2} \times 2\sigma_j \right] = 0$$

$$\sum_{q=1}^Q \frac{p(j | \hat{\theta}^{(t)}, x^q)}{(\sigma_j^2)^2} \left[ \frac{(x^q - \mu_j)^2}{2} - \frac{n}{4\pi} \times 2\sigma_j \times \sigma_j^2 \right] = 0$$

$$\sum_{q=1}^Q \frac{p(j | \hat{\theta}^{(t)}, x^q)}{(\sigma_j^2)^2} \left[ \frac{(x^q - \mu_j)^2}{2} - \frac{n}{2\pi} \sigma_j^3 \right] = 0$$

$$\Rightarrow \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) \left[ \frac{(x^q - \mu_j)^2}{\sigma_j^3} - \frac{n}{\sigma_j^3} \right] = 0 \Rightarrow \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) [(x^q - \mu_j)^2 - n \sigma_j^2] = 0$$

$$\Rightarrow n \sigma_j^2 \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) = \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) (x^q - \mu_j)^2$$

$$\Rightarrow \hat{\sigma}_{j(t+1)}^2 = \frac{\sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) (x^q - \mu_j)^2}{n \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q)}$$

$$\frac{\partial L(\theta, \lambda)}{\partial p_j} = \left[ \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) \times \frac{1}{p_j} \right] - \lambda = 0 \Rightarrow \frac{1}{p_j} \sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q) = \lambda \Rightarrow p_j = \frac{\sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q)}{\lambda}$$

$$\frac{\partial L(\theta, \lambda)}{\partial \lambda} = 0 \Rightarrow \sum_{j=1}^J p_j = 1 \Rightarrow \lambda = \sum_{j=1}^J \sum_{q=1}^Q p(j | x^q, \hat{\theta}^{(t)}) = Q \Rightarrow p_{j(t+1)} = \frac{\sum_{q=1}^Q p(j | \hat{\theta}^{(t)}, x^q)}{Q}$$

$$b) p(j|\theta_H, x^q) = ? \xrightarrow{\text{Bayes}} \frac{p(x^q|\theta_H, j) p(j|\theta_H)}{p(x^q|\theta_H)} = \frac{p(x^q|\theta_H, j) p(j|\theta_H)}{\sum_{i=1}^2 p(x^q|\theta_H, i) p(i|\theta_H)}$$

$$c) \theta = [\mu_1, \sigma_1^2, p_1, \dots, \mu_J, \sigma_J^2, p_J]^T \Rightarrow \theta = [\mu_1, \sigma_1^2, p_1, \dots, \mu_J, \sigma_J^2, p_J]^T$$

$$d) y = \begin{pmatrix} x \\ x_m \end{pmatrix} \quad \mathcal{X} = \{y^q\}_{q=1}^Q \rightarrow \text{unsupervised} \quad f(y|\theta) = f_x(x|\theta) f(x_m)$$

$\hookrightarrow x_{\text{missing}}$

$$\hat{\theta}_m = \arg \max_{\theta} \int_y f_y(y|\theta) \xrightarrow{iid} \hat{\theta}_m = \arg \max_{\theta} \prod_{q=1}^Q \int_y f_y(y^q|\theta) = \arg \max_{\theta} \prod_{q=1}^Q \int_x f(x|\theta) f(x_m^q)$$

$$\xrightarrow{L_n} \hat{\theta}_m = \arg \max_{\theta} \sum_{q=1}^Q \ln f(x^q|\theta) + \ln f(x_m^q) \rightarrow \text{stochastic function}$$

$$\Rightarrow \hat{\theta}_m_{wpo} = \arg \max_{\theta} \mathbb{E}_{x_m} \left\{ \sum_{q=1}^Q \ln f(x^q|\theta) + \ln f(x_m^q) \right\}$$

$$\Rightarrow \hat{\theta}_m_{wpo} = \arg \max_{\theta} \sum_{q=1}^Q \mathbb{E}_{x_m} \left\{ \ln f(x^q|\theta) + \ln f(x_m^q) \right\}$$

$$= \arg \max_{\theta} \sum_{q=1}^Q \int d x_m \left[ \ln f(x^q|\theta) + \ln f(x_m^q) \right] f(x_m) \quad ? \rightarrow \text{marginalization}$$

$$= \arg \max_{\theta} \sum_{q=1}^Q \int d x_m \left[ \ln f(x^q|\theta) + \ln f(x_m^q) \right] \int d x f(y|\theta)$$

در حالتی که  $f(x_m|\theta)$  و  $f(x_m^q)$  به هم وابسته نباشند،  $pdf$  را بازنویسی می‌کنیم.

در حالتی که  $f(x_m|\theta)$  و  $f(x_m^q)$  به هم وابسته باشند،  $\theta$  را با استفاده از روش  $\theta$  می‌توانیم به دست آوریم.

$$\theta = \begin{pmatrix} \theta \\ \theta \end{pmatrix}$$

d)

$$\hat{\theta}_{ml} = \underset{\theta}{\operatorname{argmax}} \sum_{q=1}^Q \int d\mathbf{x}_m \left[ \ln f(\mathbf{x}_1^q | \theta) + \ln f(\mathbf{x}_m^q | \theta) \right] f(\mathbf{x}_m | \theta)$$

این از آنجایی که مسئله  $\operatorname{argmax}$  است با استفاده از EM می‌تواند حل شود.

$$Q(\theta | \hat{\theta}^{(t)}, \mathcal{X}) = \sum_{q=1}^Q \int d\mathbf{x}_m \underbrace{\left[ \ln f(\mathbf{x}_1^q | \theta) + \ln f(\mathbf{x}_m^q | \theta) \right]}_{\text{parameter}} \underbrace{f(\mathbf{x}_m | \hat{\theta}^{(t)})}_{\text{number}}$$

E-step: Compute  $Q(\theta | \hat{\theta}^{(t)}, \mathcal{X})$

M-step:  $\hat{\theta}^{(t+1)} = \underset{\theta}{\operatorname{argmax}} Q(\theta | \hat{\theta}^{(t)}, \mathcal{X})$

در حالت کلی نمی‌توان این مسئله را به صورت EM حل کرد. برای تبدیل این مسئله به EM، فرض می‌کنیم که مدل مسئله انجام داده را در نظر بگیریم.

1- فرض استقلال قسمت مشاهده شده از دیگر ابعاد پراورگی  $f(y|\theta) = f(x_1|\theta) f(x_m|\theta)$

2- فرض سادگی در مورد distribution قسمت مشاهده نشده  $f(x_m|\theta) = f(x_m|\theta')$

$\hat{\theta}^{(0)} \rightarrow \theta$  (random)  $\rightarrow \theta'$  (use ML on  $f(x_m|\theta')$  for complete data)

از طریق ML، پارامتر  $\theta'$  را از روی داده‌های  $x_m$  یا به صورت مشاهده شده‌ها تعیین کنیم.



Problem 5)

\* Forward algorithm:  $\alpha_t(j) = P(o_1, o_2, \dots, o_t, q_t=j | \lambda)$

$$\alpha_t(j) = \sum_{i=1}^N \alpha_{t-1}(i) a_{ij} b_j(o_t)$$

↳ the previous forward path probability from the prev time step

↳ The transition probability from previous state  $q_i$  to current state  $q_j$

The state observation likelihood of the observation symbol  $o_t$  given the current state  $(j)$

$$P(O) = \sum_{j=1}^N \alpha_t(j)$$

$$\pi = [0.6, 0.4] \quad A = \begin{bmatrix} 0.7 & 0.5 \\ 0.3 & 0.6 \end{bmatrix}$$

$$B = \begin{matrix} & 0 & 1 & 2 \\ \begin{matrix} 0 \\ 1 \end{matrix} & \begin{bmatrix} 0.1 & 0.4 & 0.5 \\ 0.6 & 0.3 & 0.1 \end{bmatrix} \end{matrix} \quad S \equiv 0 \quad P \equiv 1 \quad E \equiv 2$$

$$\underline{PESEPEPEPSPEPS} \equiv \underline{12020212} \quad \underline{1012} \quad \underline{10}$$

$$\underline{SESPSEPSPESEPE} \equiv \underline{0201} \quad \underline{0210} \quad \underline{1020} \quad \underline{12}$$

$$P(PESEPEPEPSPEPS) = 2.8484 \times 10^{-7}$$


$$P(SESPSEPSPESEPE) = 1.2124 \times 10^{-7}$$

محاسبات احتمال این قسمت و پیاده سازی الگوریتم در فایل `hmm.py` قرار دارد و نتایج آن در زیر آورده شده است


Problem 5)

II.

model 1)



model 2



$$P(ABA | \gamma_1) > P(ABA | \gamma_2)$$

$$I. p(q_t | q_{t+1}, \dots, q_T) \stackrel{?}{=} p(q_t | q_{t+1})$$

$$\frac{p(q_{t+1}, q_{t+2}, \dots, q_T | q_t) p(q_t)}{p(q_{t+1}, q_{t+2}, \dots, q_T)} \stackrel{?}{=} \frac{p(q_{t+1} | q_t) p(q_t)}{p(q_{t+1})}$$

chain rule

$$\frac{p(q_{t+1} | q_t) p(q_{t+2} | q_{t+1}, q_t) \dots p(q_T | q_{T-1}, \dots, q_{t+1})}{p(q_{t+1}) p(q_{t+2} | q_{t+1}) \dots p(q_T | q_{T-1})} = \frac{p(q_{t+1} | q_t)}{p(q_{t+1})}$$

### پیوست 1: روند اجرای برنامه

برای سوال ۲ فایل jupyter notebook را باید باز کنید. این فایل نیاز به اجرا ندارد و خروجی در این فایل ذخیره شده است.

برای سوال ۶ پیاده سازی hidden markov model در فایل hmm.py آمده است.